有用性0.95以上へ。AIAへの「誘導」も試す

PWS Cup 2026 / 本番team28 / zhang_07〜09
2026年9月19日 / チーム向け説明・再現資料

今回の結果
仕組みの異なる3案とも、公式ローカル有用性は0.95以上になりました。第一候補は09：混合モデル（0.9637）です。意図的にAIAを外すこともできましたが、追加の所属推定攻撃には逆効果だったため、誘導加工は研究用の別枠にしました。

案	有用性 U	公式参照AIA 対応差の平均	公式参照MIA 平均AUC
07 コピュラ	0.952842	-0.40pt	0.5151
08 逐次条件付き	0.954674	+1.44pt	0.5238
09 混合モデル	0.963661	-1.41pt	0.5184

AIAの対応差は、生成に使った人の時刻予測成功率から、属性をそろえた未使用の人の成功率を引いたものです。正の差が大きいほど、メンバーだけが当たりやすくなっています。負の差だけで安全とは判断できません。

過去の提出物の protection=1 はユーザー報告として受け止めています。今回の3案のサーバ採点はまだありません。上の攻撃値は本番B内の4分割診断で、サーバのprotectionへ換算した値ではありません。

個別提出ZIPは submissions/ にあります。一式ZIP・PDF・結果CSVは提出しません。3案とも形式検証を通過し、別実行でZIPの一致を確認しました。

0.95を超えるために変えたこと

前回の弱点は、集団内の相関と、外れ値群の分布でした。有用性 U は4成分の最小値なので、よい項目をさらに上げても、弱い項目が残ると総合点は上がりません。

案	U_gen	U_spec	U_rare	U_valid	U=min
07	0.9610	0.9608	0.9528	0.9998	0.9528
08	0.9653	0.9547	0.9647	1.0000	0.9547
09	0.9637	0.9808	0.9747	0.9993	0.9637

① 通常層：本番Bと背景の集計を半分ずつ

周辺分布の分位点と順位相関の目標を、本番Bの通常層と本番A_bgの通常層の50:50にします。例えば「同じ分位点でBは24、背景は20」なら目標は22です（この数値は説明用）。個人の行を半分ずつ混ぜる操作ではありません。

実例としてBMIとSBPの順位相関は、本番Bが0.3815、前回04が0.3490、今回07が0.3563です。9項目全体で評価する相関点は、前回04の0.9365から07の0.9610へ改善しました。

② 外れ値層：分位点と外れ度を1回だけ補正

公開検出器で見つけたCの外れ値について、各列をBの公開外れ値層の分位点へ75%近づけます。その後、公開Mahalanobis距離の分布を合わせ、中心に寄りすぎるのを防ぎます。年齢の丸め・値域クリップも行います。

> 単に各列の分布だけを寄せた試作では、外れ値が消え、Uは約0.587まで低下しました。外れ度も戻す1回補正なら07は0.9528。5回・10回と繰り返すと相関を崩し、0.9159・0.9288でした。補正を増やせばよい、とは限りません。

真の希少24人は生成器へ渡していません。公開検出器で判定するBの51人を集計対象にしています。真のラベルは採点と評価用の層化に限って使います。

3案の「生成機構」の違い

案	新しい属性を作る仕組み	学習するイメージ
07 コピュラ	独立な正規乱数に相関を与え、各列の分位点へ戻す。	連動する強さを1つの相関構造で表す。
08 逐次条件付き	年齢・BMIから始め、既生成の列が近い背景80人を候補に、次の列を抽選。列ごとに候補を選び直す。	「この年齢・BMIなら次の血圧は？」と順に作る。
09 混合モデル	背景の正規順位を3成分GaussianMixtureで表し、成分を選んで新しい潜在値を抽選。	特徴の異なる集団を混ぜて全体を表す。

08/09は抽選後、通常層の集計相関を補正します。生成元の非線形な組合せはそれぞれ異なり、同じガウス乱数の強度を変えた3案ではありません。外れ値の合成、集計補正、転帰生成は共通化しています。

転帰は背景時刻 + 本番Bの集計解析

3案とも、発症・死亡の時刻候補を本番A_bgの対応する公開層から抽選します。独立な指数乱数の発症時計で合成人へ転帰を割り当て、本番BのCox係数に近づくよう80反復します。本番Bの発症・死亡人数も合わせます。今回09は、以前06のB由来時刻プールから背景由来へ変更しました。

添付Pythonとの違い

添付 seo-01 は3人の順位混合、Hungarian法による割当、3万回の転帰交換を使います。今回の属性生成は上表の3モデル、転帰は独立時計の係数調整です。順位変換・公開層別・Coxという概念は一部共通ですが、添付方式をそのまま再実装してはいません。

実際の09の出力例（元の個人への対応なし）

合成行	年齢	BMI	SBP	FPG	time
1	43	20.29	113.26	79.89	10.00
2	52	20.15	115.49	75.60	10.00
3	48	22.37	120.57	112.44	10.00

意図的にAIAを外す実験

公式参照AIAは、性別・県が同じCの中から、年齢・SBP・TG・HDL・ALTが最も近い行を探し、そのtimeを答えます。そこで07の県を交換し、Bに対するこの予測が外れる組合せを探しました。実験名は 07-d01 です。

交換は性別・発症・死亡が同じ合成行間に限定します。県×性別×転帰の度数、数値列、time、行数を保ちます。候補6000組のうち、正解が減る交換だけを採用しました。これは個別BのQIとtimeに合わせた加工なので、主3案より過学習しやすい実験です。

> 完成版での実測
> 本番Bへの正解は 724/1049 → 523/1049。Uは0.952842のままでした。初期試作は行順の違いで724→533でしたが、同梱の最終版は724→523です。

実例	真のtime	誘導前の予測	誘導後の予測
例1	9.999年	10.000年	9.342年
例2	9.999年	10.000年	2.979年
例3	9.999年	10.000年	2.314年

成功判定は誤差0.5年以内。上の例はすべて「正解→不正解」へ変わりました。原データの識別子は示していません。

ただし、外し方が別の手掛かりになる

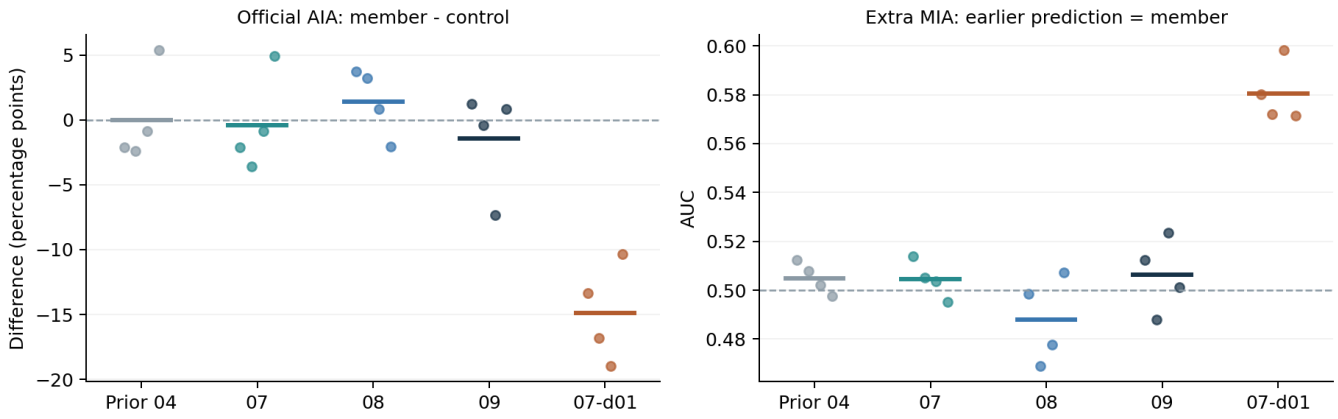
Bには10年付近の人が多いため、それらを外すには近傍の予測timeを短くする交換が有利になります。結果として、メンバーへの予測timeが対照より短くなる偏りが生じました。攻撃者は真のtimeを知らなくても、「短く予測されたらメンバーらしい」と推測できます。

4分割の追加MIA平均AUCは07の0.5044から07-d01の0.5805へ上昇。4分割すべてでHolm補正後$p<0.001$でした。公式KDE MIAは県を使わないため値が変わらず、この手掛かりを検出しません。誘導案は提出非推奨の研究用として同梱しています。

公式参照攻撃を同じ条件で比較

生成器と設定を固定してから、未使用の分割seed9601〜9604で診断しました。各734人で生成し、残り315人を対照にします。下表は性別・県・10歳年齢帯・発症をそろえたペアのAIA成功率差です。

分割	旧04	07	08	09	07-d01
9601	-2.08pt	-2.08pt	+3.75pt	+1.25pt	-13.33pt
9602	-2.40pt	-3.60pt	+3.20pt	-0.40pt	-16.80pt
9603	-0.86pt	-0.86pt	+0.86pt	-7.33pt	-18.97pt
9604	+5.37pt	+4.96pt	-2.07pt	+0.83pt	-10.33pt



点は各分割、横線は4分割平均。左は公式AIAの対応差、右は「短い予測time」を使う追加MIAのAUCです。07-d01はAIA差を下げる一方、右側の追加MIAを強めています。

公式KDE MIAの4分割平均AUCは旧04:0.5099、07:0.5151、08:0.5238、09:0.5184です。今回09は有用性が最も高く、AIA差の最大も+1.25ポイントだったため第一候補としました。匿名性が旧案より確実に改善したという意味ではありません。

07の9604分割のKDE AUCは0.5351（未補正p=0.0356）。08にも正のAIA差が残ります。3案とも公式MIA/AIAの差はHolm補正後有意ではありませんが、非有意を「痕跡なし」とは解釈しません。

評価を広げると、どこまで言えるか

誘導方法に合わせて攻撃を少し変える

時刻の推測法	07のAIA差	07-d01のAIA差
公式の1近傍	-0.40pt	-14.86pt
同じ性別・県の5近傍中央値	-0.23pt	-2.62pt
県を無視し、同じ性別の1近傍	-2.04pt	-2.04pt
全員10年（Cを参照しない）	-0.53pt	-0.53pt

県を使わなければ県交換の効果は消えます。全員10年にも効果はありません。この2点は加工の構造上の限界です。ユーザーの指摘通り、全員10年攻撃の得点をCだけで消すことは今回の目標にしていません。

本番と予備選を分ける

生成は本番team28のB・A_bg・schemaだけを使います。予備選team05のAIA分析は方向決めの前提にとどめ、今回の数値・モデル・seed調整に使っていません。前回の分析資料の要点は結果フォルダに残しています。

過学習を抑えるための扱い

通常層のB重み0.5/0.75や外れ値補正回数を、Bの有用性で比較しています。失敗を含む13件（誘導試作1件を含む）を記録しました。主3案は共通の50:50・1回補正とし、乱数seedは探索していません。新しい攻撃診断の結果では生成器を再調整していません。推薦順位は結果を見て決めています。

背景には3成分モデルや候補80人などの制限を置き、背景の個人行への距離や攻撃点を最適化していません。ただし背景自体への未知データ評価ではなく、未見母集団に対する性能は未確認です。

4分割は同じBを使い回すため独立ではありません。各分割の希少者は生成側17人・対照7人で少数です。隠れた公式対照と補正φもないため、今回のprotection=1を手元で確定することはできません。

提出・再現・確認できたこと

場所	用途
submissions/zhang_07_copula_calibrated.zip	提出候補07：ガウスコピュラ
submissions/zhang_08_conditional_calibrated.zip	提出候補08：逐次条件付き
submissions/zhang_09_mixture_calibrated.zip	提出候補09：混合モデル／今回の第一候補
experiments/zhang_07_d01_prefecture_decoy.zip	誘導実験。提出非推奨。07の派生としてd01を付番。
code/ ・ official_scoring/	匿名化・診断の再現コードと固定版公式採点器
results/	有用性内訳・試作・予測・検証ハッシュ

3案は1049行×13列でrecord_idを含みません。各ZIP直下はC.csvと本番token.txtだけ。公式形式検証に合格し、別の作業フォルダで再実行したZIPとバイト単位で一致しました。B/A_bgとの全列完全一致行、C内の重複行はいずれも0です。

再現コマンド（Python 3.12）

```
python -m venv .venv

.venv/bin/python -m pip install -r requirements.txt

.venv/bin/python code/reproduce.py --team-zip /path/to/final_team28.zip --out reproduced

.venv/bin/python code/check_attacks.py --dist reproduced/private_input --out diagnostics
```

Windowsは .venv/bin/python を .venv\Scripts\python.exe に置き換えます。原データは同梱していないため、手元の本番team28配布ZIPを指定します。予備選のZIPは拒否します。private_inputは原データの展開先であり、提出しません。

誘導実験を再現する追加コマンドはREADMEにあります。一式にはtokenを含むためチーム内用です。こちらからサーバへのアップロードはしていません。

参照：本番team28配布ZIP・schema・utility_ref、添付seo-01、前回の予備選公開結果分析、本番公式キット main-process-20260912（同梱）。完全一致がないことや公式参照攻撃の非有意は、差分プライバシーや未知攻撃への安全性を保証しません。